Σχεδίαση αναδρομικού νευρωνικού δικτύου με τη μέθοδο deep unfolding και εφαρμογή στην ανίχνευση ανωμαλιών σε βίντεο

Σιώζιος Άρης

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

Τμήμα Μηχανικών Η/Υ και Πληροφορικής

Πολυτεχνική Σχολή

Πανεπιστήμιο Ιωαννίνων

Σεπτέμβριος 2021

ΕΥΧΑΡΙΣΤΙΕΣ

Θα ήθελα να ευχαριστήσω αρχικά τον καθηγητή κύριο Κόντη για την ανάθεση του θέματος της παρούσας εργασίας, την παροχή υλικού μελέτης σχετικά με το θέμα, καθώς και για την παραχώρηση πρόσβασης σε υπολογιστή με μεγάλη επεξεργαστική ισχύ για την εκτέλεση των πειραμάτων.

Επίσης ευχαριστώ την κυρία Ευαγγελία Τσιλιγιάννη, μέλος ΕΔΙΠ του τμήματος Μηχανικών Η/Υ & Πληροφορικής του Πανεπιστημίου Ιωαννίνων, για την εξαιρετική καθοδήγηση, την
έμπρακτη συνεισφορά της και την άμεση βοήθεια που μου παρείχε όποτε χρειάστηκε.

ΠΕΡΙΕΧΟΜΕΝΑ

Κατάλογος Σχημάτων **iii**

Κατάλογος Πινάκων **v**

Κατάλογος Αλγορίθμων **vi**

Περίληψη **vii**

Abstract **ix**

1 Εισαγωγή **1**

1.1 Ανίχνευση ανωμαλιών σε βίντεο 1

1.2 Επισκόπηση μεθόδων ανίχνευσης ανωμαλιών σε βίντεο 2

1.3 Ανίχνευση ανωμαλιών σε βίντεο με χρήση νευρωνικών δικτύων 4

2 Προβλήματα αραιών αναπαραστάσεων και επίλυση με τη μέθοδο deep unfolding **5**

2.1 Αραιή αναπαράσταση σήματος 5

2.1.1 Μέθοδοι βελτιστοποίησης για κατασκευή αραιών αναπαραστάσεων 6

2.2 Συμπιεστική δειγματοληψία 7

2.3 Αντίστροφα γραμμικά προβλήματα στην επεξεργασία εικόνας 8

2.4 Σχεδίαση νευρωνικών δικτύων με τη μέθοδο deep unfolding 8

2.4.1 Learned ISTA 9

2.4.2 SISTA-RNN 9

2.4.3 LeSITA 10

3 Ανίχνευση ανωμαλιών σε βίντεο με χρήση δικτύου deep unfolding **12**

3.1 Ανακατασκευή σήματος μέσω ℓ_1−ℓ_1 ελαχιστοποίησης 12
3.2 Περιγραφή της αρχιτεκτονικής του δικτύου 15
3.3 Ανιχνευτής ανώμαλων στιγμιοτύπων 16

4 Παρουσίαση των πειραμάτων και των αποτελεσμάτων 18
4.1 Πειράματα στην ανακατασκευή σήματος 19
4.1.1 Σύνολο δεδομένων 19
4.1.2 Λεπτομέρειες υλοποίησης 19
4.1.3 Διερεύνηση Παραμέτρων 20
4.1.4 Οπτικά αποτελέσματα ανακατασκευής στιγμιοτύπων των βίντεο 23
4.2 Πειράματα στην ανίχνευση ανωμαλιών 25
4.2.1 Σύνολο δεδομένων 25
4.2.2 Αξιολόγηση μεθόδου 26
4.3 Μοντέλο χωρίς συμπίεση 27
4.4 Μοντέλο με συμπίεση 28
4.4.1 Οπτικά αποτελέσματα ανώμαλων στιγμιοτύπων 29

5 Συμπεράσματα 31

Βιβλιογραφία 32

ΚΑΤΑΛΟΓΟΣ ΣΧΗΜΑΤΩΝ

2.1 το αρχικό σήμα (a) και η αραιή του αναπαράσταση (b) 6

3.1 Αλγόριθμος 1 14
3.2 Συναρτήσεις ϕ_γ (α) LISTA,SISTA και (β) $\ell_1 - \ell_1$ ελαχιστοποίησης . . . 15
3.3 α) ένα απλό RNN πολλών κρυμμένων επιπέδων. β) το δίκτυο που υλοποιήσαμε 16

4.1 Απεικόνιση του σφάλματος εκπαίδευσης ανά εποχή. 20
4.2 Συμπιεστική δειγματοληψία: Παράδειγμα καρέ μετά τον πολλαπλασιασμό με τον πίνακα A 24
4.3 Παράδειγμα ανακατασκευής στιγμιοτύπων που έχουν ληφθεί με ρυθμό συμπίεσης 50%. Στην πρώτη σειρά παρουσιάζονται τα αρχικά στιγμιότυπα και στη δεύτερη τα αποτελέσματα ανακατασκευής. Η χαμηλή ποιότητα ανακατασκευής οφείλεται στην ανεπιτυχή αρχικοποίηση του πίνακα δειγματοληψίας A. 24
4.4 Παράδειγμα ανακατασκευής στιγμιοτύπων που έχουν ληφθεί με ρυθμό συμπίεσης 50%, διαιρέτη για τον πίνακα A το 200, 4 κρυμμένα επίπεδα και λεξικό D 1024 στηλών. 25
4.5 Παράδειγμα παραποιημένου καρέ που χρησιμοποιήθηκε για ανίχνευση ανωμαλιών. Στα αριστερά βλέπουμε το αρχικό στιγμιότυπο και δεξιά το τροποποιημένο. 26
4.6 Παράδειγμα επιτυχούς ανακατασκευής μη ομαλού στιγμιότυπου βίντεο. Στη δεξιά στήλη απεικονίζεται το στιγμιότυπο εισόδου, ενώ αριστερά παρουσιάζεται το ανακατασκευασμένο στιγμιότυπο. 28
4.7 Παραδείγματα ανακατασκευής μη ομαλών στιγμιοτύπων βίντεο. Στη δεξιά στήλη απεικονίζεται το στιγμιότυπο εισόδου, ενώ αριστερά παρουσιάζεται το ανακατασκευασμένο στιγμιότυπο. 30

4.8 Παράδειγμα ψευδώς θετικού καρέ 30

ΚΑΤΑΛΟΓΟΣ ΠΙΝΑΚΩΝ

4.1 Τεχνικά χαρακτηριστικά του μηχανήματος που εκτελέστηκαν τα πειράματα 18
4.2 Επίδραση του πλήθους ατόμων (στηλών) του λεξικού D στην επίδοση του δικτύου. 21
4.3 Επίδραση του διαιρέτη των τιμών του πίνακα A στην επίδοση του δικτύου. 22
4.4 Επίδραση του αριθμού κρυμμένων επιπέδων στην επίδοση του δικτύου. 22
4.5 Επίδραση του ρυθμού συμπίεσης στην επίδοση του δικτύου. 23
4.6 Αποτελέσματα της προτεινόμενης μεθόδου ανίχνευσης ανωμαλιών βίντεο για διάφορες τιμές κατωφλίου 27
4.7 Αποτελέσματα της προτεινόμενης μεθόδου ανίχνευσης ανωμαλιών βίντεο για διάφορες τιμές κατωφλίου 29
4.8 Πίνακας σύγχυσης για κατώφλι 25dB 29

ΚΑΤΑΛΟΓΟΣ ΑΛΓΟΡΙΘΜΩΝ

ΠΕΡΙΛΗΨΗ

Σιώζιος Άρης, Δίπλωμα, Τμήμα Μηχανικών Η/Υ και Πληροφορικής, Πολυτεχνική Σχολή, Πανεπιστήμιο Ιωαννίνων, Σεπτέμβριος 2021.
Σχεδίαση αναδρομικού νευρωνικού δικτύου με τη μέθοδο deep unfolding και εφαρμογή στην ανίχνευση ανωμαλιών σε βίντεο.
Επιβλέπων: Λυσίμαχος-Παύλος Κόντης, Καθηγητής.

Ως ανίχνευση ανωμαλιών σε βίντεο καλείται η διαδικασία εύρεσης γεγονότων που διαφέρουν από τα πιο συνηθισμένα γεγονότα που βλέπουμε σε παρόμοια βίντεο. Το πρόβλημα της εύρεσης ανώμαλων στιγμιοτύπων σε βίντεο έχει εφαρμογές σε διάφορους τομείς όπως η ιατρική, σε κάμερες ασφαλείας και άλλες αυτοματοποιημένες διαδικασίες όπως η αυτόνομη οδήγηση.

Σε αυτή την εργασία υλοποιήσαμε ένα αναδρομικό νευρωνικό δίκτυο βασισμένο στη βαθιά μάθηση για ανακατασκευή ακολουθιακών σημάτων. Συγκεκριμένα, αποκτούμε τα αλλοιωμένα καρέ των βίντεο μέσω της συμπιεστικής δειγματοληψίας και στην συνέχεια ανακτούμε τα αρχικά καρέ με μια μέθοδο που χρησιμοποιεί αραιές αναπαραστάσεις και αξιοποιεί την ομοιότητα μεταξύ γειτονικών στιγμιοτύπων. Το δίκτυο μας είναι βασισμένο σε μία μέθοδο deep unfolding, προκύπτει δηλαδή μέσω της αποτύπωσης των βημάτων μιας μεθόδου proximal που επιλύει το πρόβλημα ελαχιστοποίησης $\ell_1 - \ell_1$ σε αρχιτεκτονική νευρωνικού δικτύου.

Η κεντρική ιδέα είναι ότι κατά την εκπαίδευση του δικτύου πάνω στην ανακατασκευή των εικόνων χρησιμοποιούμε αποκλειστικά βίντεο που δεν περιέχουν ανώμαλα στιγμιότυπα. Έτσι, το δίκτυο μαθαίνει να ανακατασκευάζει σωστά μόνο φυσιολογικά καρέ και ως αποτέλεσμα όταν του δώσουμε ως είσοδο βίντεο που περιέχει κάποια μη συνηθισμένα καρέ η αναδημιουργημένη εικόνα της εξόδου δε θα είναι αρκετά όμοια με την αρχική. Στη συνέχεια το δίκτυο μας κατηγοριοποιεί κάθε καρέ ως ανώμαλο ή σύνηθες με βάση την ποιότητα της ανακατασκευής.

Η μέθοδος μας αποδίδει καλά στο πειραματικό σύνολο δεδομένων που χρησιμοποιήσαμε για να αξιολογήσουμε την επίδοση του, το οποίο ήταν το σύνολο κινούμενων χειρόγραφων ψηφίων moving MNIST. Η δοκιμή του δικτύου και σε άλλα σύνολα δεδομένων που χρησιμοποιούνται σε εργασίες σχετικές με την ανίχνευση ανωμαλιών και η σύγκριση του με αυτές αφήνεται ως πεδίο για μελλοντική έρευνα.

ABSTRACT

Aris Siozios, Diploma, Department of Computer Science and Engineering, School of Engineering, University of Ioannina, Greece, September 2021.
Diploma Thesis Title.
Advisor: Lisimachos P. Kondi, Professor.

Video anomaly detection is the process of discovering events that differ with the most common events that are presented in a video. The problem of discovering anomalous events in videos has applications in surveillance and security cameras, health monitoring and other automated processes like autonomous driving.

In this work, first, we design a deep recurrent neural network (RNN) architecture for sequential signal reconstruction. Specifically, we consider video frame acquisition under the principles of compressed sensing and we recover these frames with a sparse representation based method that takes advantage of the similarity between sequential frames. Our model is based on deep unfolding. In particular, we consider that the similarity between two consecutive frames can be captured in the representation domain using the l1 norm and we unfold the steps of a proximal gradient method that solves the $\ell_1 - \ell_1$ minimization problem.

Second, we modify the previous network to employ it for video anomaly detection. The main concept is that we train our network for reconstruction only with videos that do not contain anomalous samples. The network learns to reconstruct well only normal frames and as a result when we give to it a video containing an unusual frame as input, the reconstructed image will not be similar to the original. So our model classifies each frame of the testing set as normal or anomalous based on the reconstruction performance.

Our model performs well on the experimental dataset we used to evaluate its performance, which is the moving MNIST dataset. Trying our network on some

other dataset that are used in anomaly detection problems and comparing it with other methods is left for future work.

ΚΕΦΑΛΑΙΟ 1

Εισαγωγή

Όταν σε ένα σύνολο δεδομένων τα περισσότερα δεδομένα ακολουθούν ένα συγκεκριμένο μοτίβο, τα παραδείγματα του συνόλου δεδομένων που ξεφεύγουν από αυτά τα μοτίβα καλούνται ανωμαλίες. Το πρόβλημα της ανίχνευσης ανωμαλιών σε δεδομένα εμφανίζεται σε πολλούς τομείς της επιστήμης των υπολογιστών. Απάτες στο διαδίκτυο, διάγνωση ασθενειών μέσω της ιατρικής πληροφορικής, συστήματα παρακολούθησης χώρων, επιθέσεις σε δίκτυα, είναι μερικές περιπτώσεις που μπορεί να φανεί χρήσιμη. Σε αυτή την εργασία ασχολούμαστε μόνο με την ανίχνευση ανωμαλιών σε δεδομένα από βίντεο. Η δομή της εργασίας έχει ως εξής: Σε αυτό το κεφάλαιο θα παρουσιάσουμε το πρόβλημα ανίχνευσης ανωμαλιών σε στιγμιότυπα από βίντεο, θα δώσουμε μια σύντομη περιγραφή της λύσης που υλοποιήσαμε και θα μιλήσουμε για άλλες λύσεις του προβλήματος που έχουν προταθεί στο παρελθόν. Στο δεύτερο κεφάλαιο θα καλύψουμε το θεωρητικό υπόβαθρο που είναι απαραίτητο πριν παρουσιάσουμε αναλυτικά στο τρίτο κεφάλαιο την λύση που υλοποιήσαμε. Τέλος στο τέταρτο κεφάλαιο παρουσιάζουμε κάποιες λεπτομέρειες σχετικές με την υλοποίηση, τα πειράματα που κάναμε για την αξιολόγηση της λύσης μας καθώς και κάποια οπτικά αποτελέσματα.

1.1 Ανίχνευση ανωμαλιών σε βίντεο

Συνήθως όταν μιλάμε για ανωμαλίες σε δεδομένα από βίντεο αναφερόμαστε σε γεγονότα που λαμβάνουν χώρα σπάνια σε ένα σύνολο από βίντεο και υποδηλώνουν ασυνήθιστη συμπεριφορά. Μέθοδοι ανίχνευσης ανωμαλιών εφαρμόζονται κυρίως

σε βίντεο από συστήματα παρακολούθησης όπως κάμερες ασφαλείας, σε ιατρικά δεδομένα, σε βίντεο από κάμερες αυτοκινήτων όπου ως ασυνήθιστα γεγονότα καταγράφονται τροχαία ατυχήματα. Το τι θεωρείται ανωμαλία εξαρτάται από το που προέρχονται τα δεδομένα. Για παράδειγμα, σε βίντεο από κάμερες ασφαλείας που καταγράφουν απλά πεζούς να κινούνται σε κάποιο προαύλιο ως ανωμαλία μπορεί να θεωρηθεί ένας άνθρωπος πάνω σε ένα ποδήλατο ή κάποιο άλλο διερχόμενο όχημα, ενώ σε βίντεο από κάμερες ασφαλείας καταστήματος οποιαδήποτε παραβατική συμπεριφορά μπορεί να θεωρηθεί ως ασυνήθιστη.

Άρα αυτό που γίνεται εύκολα αντιληπτό από το παραπάνω είναι πως το τι θεωρείται φυσιολογικό και τι όχι είναι σχετικό και ασαφές. Για παράδειγμα, έστω πως σε ένα σύνολο δεδομένων που δείχνει πεζούς ανθρώπους να κινούνται προς κάποια κατεύθυνση ο ένας σε απόσταση από τον άλλον και όλοι οι πεζοί είναι μετρίου αναστήματος. Αν ξαφνικά εμφανιστεί ένας πανύψηλος άνθρωπος ή δύο άνθρωποι που περπατούν πιασμένοι χέρι χέρι το σκηνικό θα διαφέρει από το σύνηθες και άρα κάποια μέθοδος ανίχνευσης ανωμαλιών θα κρίνει τα συγκεκριμένα παραδείγματα ως μη φυσιολογικά, κάτι που δεν ισχύει. Οπότε για να πετύχει μια μέθοδος θα πρέπει να υπάρχει πληθώρα από φυσιολογικά γεγονότα στο σύνολο δεδομένων που θα χρησιμοποιηθεί για την εκπαίδευσή της [1].

1.2 Επισκόπηση μεθόδων ανίχνευσης ανωμαλιών σε βίντεο

Σε αυτή την ενότητα παρουσιάζουμε κάποιες σημαντικές μεθόδους που χρησιμοποιήθηκαν στο παρελθόν πάνω στην ανίχνευση ανωμαλιών. Ειδικότερα, θα αναφερθούμε σε δύο κατηγορίες μεθόδων, δηλαδή, σε μεθόδους που χρησιμοποιούν αραιές αναπαραστάσεις και μεθόδους που βασίζονται σε δίκτυα βαθιάς μάθησης.

Στην εργασία [2] παρουσιάστηκε μια μέθοδος μάθησης χωρίς επίβλεψη για ανακατασκευή βίντεο μέσω αραιής κωδικοποίησης, όπου στην διάρκεια της εκπαίδευσης μεταβάλλονται οι τιμές κάποιων λεξικών μετασχηματισμού και στην συνέχεια ο αλγόριθμος αποφασίζει με βάση το σφάλμα ανακατασκευής του σήματος. Επιπλέον, στην εργασία [3] βλέπουμε μια παρόμοια προσέγγιση, μόνο που οι συγγραφείς αντί να εκπαιδεύσουν ολόκληρα λεξικά που καταλαμβάνουν πολύ χώρο στη μνήμη, μαθαίνουν απλά τις αραιές αναπαραστάσεις των βίντεο και έτσι επιτυγχάνεται μια πιο γρήγορη και με λιγότερο κόστος λύση, λόγω του ότι οι με-

τασχηματισμοί δεσμεύουν αρκετό χώρο στη μνήμη και συχνά δεν είναι απαραίτητη όλη η πληροφορία που παρέχουν.

Άλλες λύσεις που βασίζονται στις αραιές αναπαραστάσεις βρίσκουμε στις εργασίες [4] και [5]. Συγκεκριμένα, στην [4] βρίσκουμε μια μέθοδο ανακατασκευής αραιού σήματος μέσω του ιστογράμματος οπτικής ροής που βγαίνει από τα καρέ της εισόδου και στη συνέχεια μέσω ενός μετασχηματισμού και της ελαχιστοποίησης ℓ_1 υπολογίζουν το κόστος αραιής ανακατασκευής για να μετρηθεί η φυσιολογικότητα των δεδομένων. Και αυτή η λύση όπως και οι υπόλοιπες χρησιμοποιούν ως σύνολο εκπαίδευσης μόνο φυσιολογικά παραδείγματα. Η εργασία [5] αποτελεί συνέχεια της εργασίας [3], όπου με κάποιες βελτιώσεις επιτεύχθηκε η διαχείριση και δυναμικών αλλά και μεγάλης κλίμακας δεδομένων. Εκτός από αυτό, υπήρξε και σημαντική βελτίωση ως προς τον χρόνο, καθώς από τα 150 καρέ το δευτερόλεπτο που εντόπιζε η αρχική μέθοδος περάσανε στα 1000 καρέ ανά δευτερόλεπτο.

Επιπλέον, έχουν παρουσιαστεί και προσεγγίσεις του προβλήματος βασισμένες σε μοντέλα βαθιάς μάθησης. Οι συγγραφείς του [6] χρησιμοποίησαν ένα συνελικτικό νευρωνικό δίκτυο και το εκπαίδευσαν με φυσιολογικά δεδομένα από βίντεο. Έπειτα, με βάση ένα σκορ που υπολογίζουν με βάση το σφάλμα ανακατασκευής των βίντεο αποφασίζουν για την κατηγοριοποίηση των βίντεο σε ανώμαλα και μη. Επειδή όμως τα δίκτυα αποφασίζουν κυρίως με βάση την χρονική κατανομή των στιγμιοτύπων και όχι την χωρική, δεν αποδίδουν τόσο καλά, στην εργασία [7] αντί για απλά συνελικτικά δίκτυα χρησιμοποίησαν συνελικτικά δίκτυα LSTM (Long short-term memory) μαζί με έναν κωδικοποιητή και δύο αποκωδικοποιητές. Τα δίκτυα LSTM είναι μια ειδική κατηγορία αναδρομικών νευρωνικών δικτύων. Μια διαφορά που έχει η μέθοδος της εργασίας [7] είναι ότι εκτός από ανακατασκευή των καρέ το δίκτυο τους κάνει και πρόβλεψη για τα μελλοντικά στιγμιότυπα του βίντεο, οπότε χρησιμοποιούν και αυτό το μέσο σφάλμα για να ανακαλύψουν τυχόν ανωμαλίες στα δεδομένα, με την ίδια λογική όπως και με το σφάλμα ανακατασκευής.

Μια άλλη προσέγγιση βασισμένη σε μέθοδο βαθιάς μάθησης βλέπουμε στην εργασία [8], όπου οι συγγραφείς χρησιμοποιούν δύο παραγωγικά αντιπαραθετικά δίκτυα (Generative Adversarial Networks, GAN's). Όπως στις μεθόδους που αναλύσαμε προηγουμένως, έτσι και εκεί βλέπουμε ξανά το σκεπτικό ότι τα μη φυσιολογικά καρέ δεν ανακατασκευάζονται με επιτυχία.

1.3 Ανίχνευση ανωμαλιών σε βίντεο με χρήση νευρωνικών δικτύων

Όπως αναφέρθηκε στην προηγούμενη ενότητα, η χρήση δικτύων βαθιάς μάθησης για την ανίχνευση ανωμαλιών σε βίντεο είναι ιδιαίτερα δημοφιλής. Ένα μειονέκτημα των νευρωνικών δικτύων είναι η λειτουργία τους ως ''μαύρα κουτιά'', δηλαδή είναι δύσκολο να καταλάβει κανείς τι ακριβώς μαθαίνει το δίκτυο κατά την εκπαίδευση. Για το λόγο αυτό πρόσφατες εργασίες προσπαθούν να χρησιμοποιήσουν αποτελέσματα από συμβατικά μοντέλα στη σχεδίαση ενός νευρωνικού δικτύου. Η μέθοδος deep unfolding μετατρέπει έναν επαναληπτικό αλγόριθμο σε μορφή νευρωνικού δικτύου. Κατά την εκπαίδευση οι παράμετροι του αλγορίθμου μαθαίνονται από τα δεδομένα με αποτέλεσμα ο αλγόριθμος να δίνει ακριβή αποτελέσματα υλοποιώντας έναν μικρό αριθμό επαναλήψεων. Η μέθοδος έχει χρησιμοποιηθεί σε προβλήματα ανακατεσκευής εικόνας και βίντεο. Οπότε η κεντρική ιδέα είναι να χρησιμοποιήσουμε μια μέθοδο deep unfolding για ανακατασκευή σήματος και να εκπαιδεύσουμε το μοντέλο μας μόνο με δεδομένα που δεν περιέχουν ασυνήθιστα γεγονότα. Με αυτό τον τρόπο εξασφαλίζουμε ότι μετά την εκπαίδευση του δικτύου, δίνοντας ως είσοδο δεδομένα που περιλαμβάνουν ανωμαλίες η ανακατασκευή δεν θα είναι τόσο καλή όσο θα είναι πάνω σε φυσιολογικά δεδομένα, παρόμοια με αυτά του συνόλου εκπαίδευσης.

ΚΕΦΑΛΑΙΟ 2

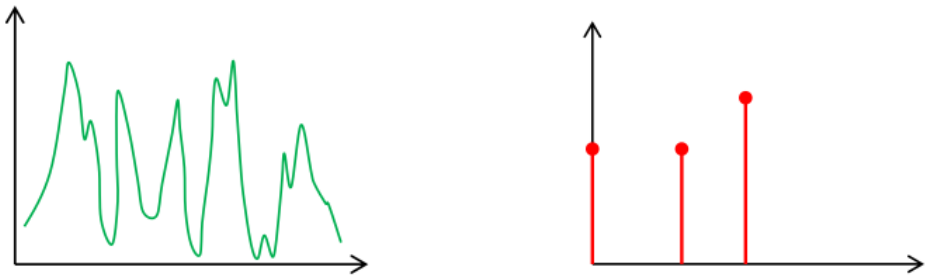
Προβλήματα αραιών αναπαραστάσεων και επίλυση με τη μέθοδο deep unfolding

2.1 Αραιή αναπαράσταση σήματος

Ένα σήμα s $\in \mathbb{R}^m$ γραμμένο σε μορφή διανύσματος καλείται αραιό όταν οι περισσότερες συνιστώσες του διανύσματος αυτού είναι ίσες με το μηδέν[9]. Το πλήθος των μη μηδενικών συνιστωσών του s δίνεται υπολογίζοντας την νόρμα 0 του σήματος, θέτοντας $0^0 = 0$:

$$\|s\|_0 = |s_1|^0 + |s_2|^0 + \cdots + |s_m|^0$$

Το βασικό πλεονέκτημα των αραιών σημάτων αυτών είναι ότι μας αποκαλύπτουν κάποια κρυμμένα χαρακτηριστικά του αρχικού σήματος και γενικά βοηθούν στο να αναπαρασταθεί αυτό σε μια πιο συμπαγή μορφή. Ένα παράδειγμα αραιής αναπαράστασης σήματος δίνεται στο Σχήμα 2.1. Όπως βλέπουμε το αραιό σήμα στο Σχήμα 2.1 (b) έχει μόνο 3 μη μηδενικούς συντελεστές.



(a) Original signal (b) Transformed sparse signal

Σχήμα 2.1: το αρχικό σήμα (a) και η αραιή του αναπαράσταση (b)

Δοθέντος ενός m-διάστατου σήματος s $\in \mathbb{R}^m$ και ενός γραμμικού μετασχηματισμού D $\in \mathbb{R}^{m \times m}$, το σήμα s μπορεί να γραφτεί στην μορφή $s = Dh$, όπου h είναι η αναπαράσταση του s στον χώρο του μετασχηματισμού. Αν οι μη μηδενικοί συντελεστές του h είναι λιγότεροι από το πλήθος των συνιστωσών του s τότε το σήμα h είναι η αραιή αναπαράσταση του s και ο μετασχηματισμός D καλείται αραιός μετασχηματισμός. Τέτοιοι μετασχηματισμοί είναι ο διακριτός μετασχηματισμός Fourier καθώς και ο διακριτός μετασχηματισμός συνημιτόνου, και ένας λόγος που χρησιμοποιούνται κατά κόρον είναι και το ότι δίνουν αραιές αναπαραστάσεις. Επειδή όμως οι ορθογώνιοι μετασχηματισμοί δεν μας δίνουν πάντα καλές αραιές αναπαραστάσεις, συχνά χρησιμοποιούνται υπερπλήρεις μετασχηματισμοί, δηλαδή πίνακες διάστασης $m \times n$, με n>m. Οι πίνακες αυτοί αναφέρονται ως λεξικά (dictionaries). Αυτό σημαίνει ότι ο χώρος του μετασχηματισμού είναι μεγαλύτερος από τον αρχικό χώρο $\mathbb{R}^m$ του σήματος. Σε αυτή την περίπτωση έχουμε:

$$s = Dh, D \in \mathbb{R}^{m \times n}, n > m \tag{2.1}$$

Για την επίλυση της (2.1), δηλαδή για την κατασκευή καλών αραιών αναπαραστάσεων έχουν προταθεί διάφορες τεχνικές οι οποίες αναφέρονται σε επόμενη υποενότητα.

2.1.1 Μέθοδοι βελτιστοποίησης για κατασκευή αραιών αναπαραστάσεων

Όπως είπαμε το πόσο αραιό είναι ένα σήμα μπορεί να μετρηθεί από την τιμή της νόρμας-0. Με βάση αυτό προκύπτει πως για την εύρεση καλών αραιών αναπαρα-

στάσεων μια καλή λύση είναι η ελαχιστοποίηση του μεγέθους αυτού, δηλαδή:

$$\min_{h\in\mathbb{R}^m} \|h\|_0, s = Dh \tag{2.2}$$

Επειδή όμως το πρόβλημα (2.2), το οποίο καλείται ελαχιστοποίηση ℓ_0 είναι δυσεπίλυτο, μία ακόμη λύση είναι να χρησιμοποιηθεί μια πιο λεία συνάρτηση από την νόρμα 0. Μια τέτοια συνάρτηση είναι η νόρμα 1. Οπότε το νέο πρόβλημα ελαχιστοποίησης που προκύπτει είναι:

$$\min_{h\in\mathbb{R}^m} \|h\|_1, s = Dh. \tag{2.3}$$

όπου $\|h\|_1 = \sum_{i=1}^{m} |h_i|$. Το πρόβλημα αυτό αναφέρεται ως ελαχιστοποίηση ℓ_1. Μέσω αυτής της πρακτικής έχουμε ένα πιο απλό πρόβλημα προς επίλυση απ ότι το (2.2). Οι συγγραφείς του [10] έχουν μελετήσει τις συνθήκες που εξασφαλίζουν ότι τα δύο προβλήματα ελαχιστοποίησης είναι ισοδύναμα.

Ένα παρόμοιο πρόβλημα είναι το λεγόμενο πρόβλημα αραιής προσέγγισης (sparse approximation problem). Το πρόβλημα αυτό ελαχιστοποιεί το σφάλμα $\|s-Dh\|_2$ και χρησιμοποιεί μια παράμετρο κανονικοποίησης λ η οποία ελέγχει το πόσο επηρεάζεται η λύση από την αραιότητα του σήματος.

$$\min_{h\in\mathbb{R}^m} \frac{1}{2}\|s - Dh\|_2^2 + \lambda\|h\|_1, \tag{2.4}$$

Το πρόβλημα (2.4) καλείται και τελεστής LASSO (least absolute shrinkage and selection operator)[11].

2.2 Συμπιεστική δειγματοληψία

Έστω ένα σήμα $h \in \mathbb{R}^N$ σε μορφή διανύσματος. Η συμπιεστική δειγματοληψία (compressive sensing) μας δίνει μας δίνει μια συμπιεσμένη αναπαράσταση $x \in \mathbb{R}^m$ του σήματος h μέσω ενός πίνακα A διάστασης $m \times N, m < N$. Ο πίνακας A λέγεται πίνακας δειγματοληψίας ή πίνακας προβολής ή πίνακας μετρήσεων και δεν εξαρτάται από το σήμα h. Η συμπιεσμένη αναπαράσταση του σήματος προκύπτει από τον εξής πολλαπλασιασμό:

$$x = Ah, \tag{2.5}$$

Είναι εφικτό να ανακτήσουμε ξανά το σήμα από το x, λύνοντας προβλήματα ελαχιστοποίησης είτε ℓ_0 είτε ℓ_1, υποθέτοντας ότι το σήμα h είναι αραιό [12].

Το πρόβλημα της συμπιεστικής δειγματοληψίας εμφανίζεται συχνά σε εφαρμογές της επεξεργασίας σήματος όπως η επεξεργασία και η ανάλυση δεδομένων υψηλής διάστασης, δηλαδή δεδομένα από βίντεο και άλλα πολυμέσα ή σε βιοϊατρικά δεδομένα, καθώς μέσω της συμπιεστικής δειγματοληψίας μπορεί ένα σήμα να ανακτηθεί εύκολα από δεδομένα μικρότερης διάστασης.

2.3 Αντίστροφα γραμμικά προβλήματα στην επεξεργασία εικόνας

Σε διάφορες εφαρμογές της επεξεργασίας εικόνας, [13] όπως και στην ανακατασκευή σήματος καλούμαστε να επιλύσουμε προβλήματα της μορφής:

$$x = As + \eta, \tag{2.6}$$

με $s \in \mathbb{R}^m$ να είναι το διάνυσμα της αρχικής εικόνας, ενώ $A \in \mathbb{R}^{k \times m}, k < m$ είναι ένας γραμμικός τελεστής που μειώνει την διάσταση της εικόνας και $\eta \in \mathbb{R}^k$ ο θόρυβος. Ένας τρόπος επίλυσης της σχέσης (2.6) βασίζεται στις αραιές αναπαραστάσεις [14]. Δηλαδή αντί να λύσουμε ως προς s, παίρνουμε ως δεδομένο ότι το s έχει μια αραιή αναπαράσταση h η οποία όπως είπαμε παραπάνω μπορεί να βρεθεί από το πρόβλημα (2.4), και στη συνέχεια λαμβάνοντας υπόψιν την σχέση (2.6) ο υπολογισμός του s μπορεί να γίνει λύνοντας το πρόβλημα ελαχιστοποίησης:

$$\min_{h \in \mathbb{R}^m} \frac{1}{2} \|x - ADh\|_2^2 + \lambda \|h\|_1, \tag{2.7}$$

Διάφορες μέθοδοι έχουν υλοποιηθεί στο παρελθόν για την επίλυση του προβλήματος (2.7). Κάποιες εξ αυτών περιγράφονται στις επόμενες παραγράφους.

2.4 Σχεδίαση νευρωνικών δικτύων με τη μέθοδο deep unfolding

Με τον όρο deep unfolding αναφερόμαστε σε μία μέθοδο που ουσιαστικά μετατρέπει επαναληπτικούς αλγορίθμους βελτιστοποίησης σε νευρωνικά δίκτυα, ώστε να επιλύει αποδοτικά προβλήματα πάνω στην μηχανική μάθηση, στην επεξεργασία εικόνας και σήματος και στα τηλεπικοινωνιακά συστήματα [15]. Οι μέθοδοι που αναλύονται στις επόμενες υπο-ενότητες είναι όλες αυτής της μορφής.

2.4.1 Learned ISTA

Οι συγγραφείς του [16] προτείνουν για την επίλυση του (2.7) έναν επαναληπτικό αλγόριθμο γνωστό ως Iterative Soft Thresholding Algorithm (ISTA), ο οποίος σε κάθε επανάληψη t υπολογίζει το αραιό σήμα ως εξής:

$$h^t = \phi_\gamma(h^{t-1} - \frac{1}{L}V^T(Vh^t - x), h^0 = 0, V = AD, \tag{2.8}$$

όπου ϕ_γ ο τελεστής soft thresholding $\phi_\gamma(u) = sign(u)(0, |u| - \gamma)$ και L μία σταθερά. Στην εργασία [17] υλοποιήθηκε ένα νευρωνικό δίκτυο πρόσθιας τροφοδότησης με βάση τα βήματα του (2.8). Συγκεκριμένα, κάθε επανάληψη του αλγορίθμου (ISTA) μπορεί σε κάθε επίπεδο του δικτύου να γραφτεί ως $h^t = \phi_\gamma(Sh^{t-1} + Wx)$, με $S = I - V^TV$ και $W = \frac{1}{L}V^T$.

Κατά την εκπαίδευση του δικτύου, οι παράμετροι S, W, γ υπολογίζονται από τα δεδομένα. Συνεπώς το μοντέλο που λαμβάνουμε μπορεί να θεωρηθεί ως ένας επαναληπτικός αλγόριθμος προσαρμοσμένος στα δεδομένα, ο οποίος μπορεί να δώσει αραιές αναπαραστάσεις υψηλής ακρίβειας σε λίγες μόνο επαναλήψεις. Η μέθοδος αυτή ονομάζεται LISTA (Learned ISTA) και έχει αποδειχθεί ότι έχει πολύ καλή απόδοση στην ανακατασκευή σήματος.

2.4.2 SISTA-RNN

Μια ειδική κατηγορία νευρωνικών δικτύων τα οποία έχουν χρησιμοποιηθεί για ανακατασκευή σήματος είναι τα αναδρομικά (Recurrent Neural Networks-RNN). Πρόκειται για νευρωνικά δίκτυα με βρόχους ανάδρασης που διαδίδουν την πληροφορία ανάμεσα σε διαφορετικά επίπεδα και ακολουθιακά βήματα. Σε ένα RNN πολλών κρυμμένων επιπέδων, όπως βλέπουμε και στο Σχήμα 3.2(a) οι κάθετες συνδέσεις μεταξύ των νευρώνων διαδίδουν πληροφορία που παράγεται από ένα στιγμιότυπο του σήματος της εισόδου, ενώ οι οριζόντιες διαδίδουν στο δίκτυο πληροφορία που προέρχεται από τα προηγούμενα στιγμιότυπα. Σε κάθε κρυμμένο επίπεδο K, η αναπαράσταση του σήματος υπολογίζεται από την παρακάτω σχέση:

$$h^t = \begin{cases} \phi(W^{(1)}h_{t-1}^{(1)} + Ux_t), & k = 1, \\ \phi(W^{(k)}h_{t-1}^{(k)} + s^k h_t^{(k-1)}), & k > 1, \end{cases} \tag{2.9}$$

όπου ϕ είναι η μη γραμμική συνάρτηση ενεργοποίησης και συνήθως είναι είτε εφαπτομενική είτε RELU(Rectified Linear Unit), και οι W, S, U είναι αφινικοί μετασχηματισμοί. Τα δίκτυα αυτά δεν αξιοποιούν ικανοποιητικά την γνώση που προέρχεται

από τις αραιές αναπαραστάσεις, οπότε για τον λόγο αυτό οι συγγραφείς του [18] υλοποίησαν ένα πολυεπίπεδο RNN παρόμοιας λογικής με το LISTA το οποίο επιλύει το εξής πρόβλημα ελαχιστοποίησης:

$$\min_{h_t} \frac{1}{2}\|x - ADh_t\|_2^2 + \lambda_1\|h_t\|_1 + \frac{\lambda_2}{2}\|Dh_t - FDh_{t-1}\|_2^2, \tag{2.10}$$

όπου $F \in \mathbb{R}^{n\times n}$ είναι ένας πίνακας συσχέτισης των στιγμιοτύπων s_t, s_{t-1}, λ_1, λ_2 είναι παράμετροι κανονικοποίησης και ως συνάρτηση ενεργοποίησης χρησιμοποιείται η ϕ_γ όπως και στον LISTA (2.8). Το δίκτυο αυτό ονομάζεται SISTA-RNN.

2.4.3 LeSITA

Στην εργασία [19] περιγράφεται άλλος ένας τρόπος επίλυσης του προβλήματος (2.6). Συγκεκριμένα, η λύση βασίζεται στο ότι η επίδοση των μεθόδων ανακατασκευής σήματος μπορεί να βελτιωθεί αν υπάρχει κάποιο συσχετιζόμενο σήμα με το σήμα x. Ειδικότερα, αν είναι διαθέσιμο ένα σήμα $y \in \mathbb{R}^d$ συσχετιζόμενο με το x, το y καλείται πλεονάζουσα πληροφορία (side information, SI) και θεωρώντας ότι τα y και x έχουν όμοιες αραιές αναπαραστάσεις $\omega, h \in \mathbb{R}^n$ αντίστοιχα, τότε η αραιή αναπαράσταση του x μπορεί να βρεθεί μέσω της επίλυσης του προβλήματος ελαχιστοποίησης ℓ_1−ℓ_1:

$$\min_{h} \frac{1}{2}\|ADh - x\|_2^2 + \lambda(\|h\|_1 + \|h - \omega\|_1), \tag{2.11}$$

Τις περισσότερες φορές και ειδικά στην περίπτωση που μιλάμε για ακολουθιακά σήματα όπως είναι τα βίντεο, ως side information μπορεί να χρησιμοποιηθεί προηγούμενο στιγμιότυπο του σήματος, δηλαδή το προηγούμενο καρέ. Για την ελαχιστοποίηση της σχέσης (2.11) μπορεί να χρησιμοποιηθεί μια μέθοδος proximal της μορφής:

$$h^t = \xi_\mu(h^{t-1} - \frac{1}{L}F^T(Fh^{t-1} - x)), h^0 = 0. \tag{2.12}$$

όπου $F = AD$, L ένα άνω φράγμα στη συνθήκη Lipschitz του $\nabla f, f = \frac{1}{2}\|ADh - x\|_2^2$, $\mu = \frac{\lambda}{L}$ και ξ_μ ένας τελεστής proximal ο οποίος για $i = 1, \ldots, n$ δίνεται από τις

παρακάτω σχέσεις:

$$\xi_\mu(u_i) = \begin{cases} u_i + 2\mu, & u_i < 2\mu, \\ 0, & -2\mu \leq u_i \leq 0, \\ u_i, & 0 \leq u_i \leq \omega_i, \\ \omega_i, & \omega_i \leq u_i \leq \omega_i + 2\mu, \\ u_i - 2\mu, & u_i \geq \omega_i + 2\mu \end{cases}$$

για $\omega_i \geq 0$ και

$$\xi_\mu(u) = \begin{cases} u_i + 2\mu, & u_i < \omega_i - 2\mu, \\ \omega_i, & \omega_i - 2\mu \leq u_i \leq \omega_i, \\ u_i, & \omega_i < u_i < 0, \\ 0, & 0 \leq u_i \leq 2\mu, \\ u_i - 2\mu, & u_i > 2\mu \end{cases} \tag{2.13}$$

για $\omega_i < 0$. Η (2.11) ονομάζεται Side information-driven iterative soft-Thresholding Algorithm(SITA). Θέτοντας $Q = I - \frac{1}{L}F^TF, R = \frac{1}{L}F^T$ έχουμε μια σχέση $h^t = \xi_\mu(Qh^{t-1} - Rx)$, η οποία μοιάζει με την αντίστοιχη σχέση για τις αραιές αναπαραστάσεις του LISTA, με μόνη διαφορά την συνάρτηση ενεργοποίησης. Γράφοντας την (2.11) στην παραπάνω μορφή έχουμε όπως και στον LISTA μια σχέση που μπορεί να χρησιμοποιηθεί σε ένα νευρωνικό δίκτυο, είτε αναδρομικό είτε απλό δίκτυο πρόσθιας τροφοδότησης, με τις παραμέτρους Q, R, μ να ενημερώνονται κατά την εκπαίδευση του δικτύου. Η μέθοδος αυτή ονομάστηκε LeSITA (Learned SITA).

ΚΕΦΑΛΑΙΟ 3

Ανίχνευση ανωμαλιών σε βίντεο με χρήση δικτύου deep unfolding

Σε αυτή την ενότητα περιγράφουμε αναλυτικά την μέθοδο που υλοποιήσαμε για την ανίχνευση ανωμαλιών σε στιγμιότυπα βίντεο. Για την ανακατασκευή των ακολουθιακών σημάτων υλοποιήσαμε ένα νευρωνικό δίκτυο όπως έχει προταθεί στο [20]. Το δίκτυο αυτό έχει την μορφή ενός αναδρομικού νευρωνικού δικτύου (RNN). Η διαφοροποίηση από ένα κλασσικό RNN είναι ότι υλοποιεί τα βήματα της μεθόδου (2.12) που επιλύει το πρόβλημα της ελαχιστοποίησης $\ell_1-\ell_1$.

Στη συνέχεια, χρησιμοποιούμε το δίκτυο αυτό για να ανακατασκευάσουμε όλα τα βίντεο, και η κεντρική ιδέα είναι ότι αφού το δίκτυο εκπαιδευτεί στο να ανακατασκευάζει βίντεο στα οποία δεν συμβαίνει κάτι μη φυσιολογικό, δεν θα μπορεί να αποδώσει εξίσου καλά στην ανακατασκευή δεδομένων που περιέχουν κάτι ασυνήθιστο.

3.1 Ανακατασκευή σήματος μέσω $\ell_1-\ell_1$ ελαχιστοποίησης

Σε αυτή την υποενότητα περιγράφονται τα βήματα που ακολουθήσαμε ώστε να υλοποιήσουμε το δίκτυο μας και να πετύχουμε καλή απόδοση στην ανακατασκευή των καρέ των βίντεο.

Η λύση που ακολουθήσαμε βασίζεται στην δυνατότητα ενός σήματος $s_t = Dh_t$ να

ανακτηθεί από το αλλοιωμένο σήμα x_t μέσω της επίλυσης του ακόλουθου προβλήματος ελαχιστοποίησης:

$$\min_{h_t} \frac{1}{2}\|x_t - ADh_t\|_2^2 + \lambda_1\|h_t\|_1 + \lambda_2\|h_t - Gh_{t-1}\|_1, \tag{3.1}$$

όπου ο G είναι ο αφινικός μετασχηματισμός ο οποίος τονίζει την συσχέτιση (βαθμό ομοιότητας) μεταξύ των αραιών αναπαραστάσεων δύο διαδοχικών στιγμιοτύπων του σήματος και λ_1, λ_2 είναι παράμετροι κανονικοποίησης. Ο πίνακας A είναι ένας πίνακας δειγματοληψίας που στην ουσία μας δίνει μια συμπιεσμένη αναπαράσταση του αρχικού σήματος, $x_t = As_t$. Το (3.1) έχει την ίδια μορφή με το πρόβλημα (2.11), δηλαδή είναι ένα πρόβλημα ελαχιστοποίησης ℓ_1−ℓ_1. Για την συσχέτιση μεταξύ των h_t και h_{t-1} χρησιμοποιείται η Νορμα-1, εν αντιθέσει με τη συσχέτιση μεταξύ των s_t και Fs_t στον SISTA όπου χρησιμοποιείται η νόρμα-2.

Η αντικειμενική συνάρτηση (3.1) χωρίζεται σε δύο μέρη: την $f(h_t) = \frac{1}{2}\|x_t - ADh_t\|_2^2$ και την $g(h_t) = \lambda_1\|h_t\|_1 + \lambda_2\|h_t - Gh_{t-1}\|_1$. Η $f(h_t)$ είναι διαφορίσιμη συνάρτηση ενώ η $g(h_t)$ είναι συνάρτηση χωρίς συνεχή πρώτη παράγωγο, είναι δηλαδή μη λεία.
Με βάση αυτά, το δίκτυο που υλοποιήσαμε ελαχιστοποιεί την (3.1) με μία μέθοδο proximal gradient και μας δίνει καλές αραιές αναπαραστάσεις των στιγμιοτύπων του σήματος της εισόδου, ώστε πολλαπλασιάζοντας τις αναπαραστάσεις h_t με τον μετασχηματισμό D να έχουμε το ανακατασκευασμένο σήμα s_t.

Στη συνέχεια περιγράφονται τα βήματα του αλγορίθμου που υλοποιεί την παραπάνω μέθοδο βελτιστοποίησης για να πάρουμε τις αραιές αναπαραστάσεις των στιγμιοτύπων της εισόδου.

Στο Σχήμα 3.1 βλέπουμε τον αλγόριθμο που προτάθηκε στην εργασία [20]. Η διαφορά του δικού μας αλγορίθμου είναι ότι για τον πίνακα A χρησιμοποιήσαμε τυχαίες τιμές από μία ομοιόμορφη κατανομή. Ο αλγόριθμος αυτός παίρνει ως είσοδο τα στιγμιότυπα από ένα σήμα $x_{1:T}$, τους πίνακες A, D και τον αφινικό μετασχηματισμό G, το αρχικό αραιό σήμα $h_0^{(k)}$, τις παραμέτρους κανονικοποίησης λ_1, λ_2 και την παράμετρο α που αναπαριστά τον ρυθμό μάθησης στο βήμα 5 του αλγορίθμου. Συγκεκριμένα, στο βήμα 5 εφαρμόζεται ένα βήμα gradient descent**(κάθοδος βασισμένη στην κλίση)** πάνω στην συνάρτηση $f(h_t)$ και στην συνέχεια στο βήμα 6 συναντάμε τον proximal τελεστή ϕ_γ που ουσιαστικά παίζει τον ρόλο της συνάρτησης ενεργοποίησης και μας δίνει τις τιμές των αραιών αναπαραστάσεων του σήματος μέσω της ακόλουθης μαθηματικής σχέσης:

Algorithm 1: The proposed proximal gradient method for sequential signal recovery via ℓ_1-ℓ_1 minimization.

Input: Sequence of measurements $\boldsymbol{x}_{1:T}$, measurement matrix $\mathbf{A}$, dictionary $\mathbf{D}$, affine transformation $\mathbf{G}$, initial sparse code $\boldsymbol{h}_0^{(K)}$, parameters α, λ_1, λ_2.
for $t = 1,\ldots,T$ **do**
  $\boldsymbol{h}_t^{(1)} = \mathbf{G}\boldsymbol{h}_{t-1}^{(K)}$
  for $k = 1$ *to* K **do**
    $\boldsymbol{u} = [\mathbf{I} - \frac{1}{\alpha}\mathbf{D}^T\mathbf{A}^T\mathbf{A}\mathbf{D}]\boldsymbol{h}_t^{(k-1)} + \frac{1}{\alpha}\mathbf{D}^T\mathbf{A}^T\boldsymbol{x}_t$
    $\boldsymbol{h}_t^{(k)} = \phi_{\frac{\lambda_1}{\alpha},\frac{\lambda_2}{\alpha},\mathbf{G}\boldsymbol{h}_{t-1}^{(K)}}(\boldsymbol{u})$
  end
end
return $\boldsymbol{h}_{1:T}^{(K)}$

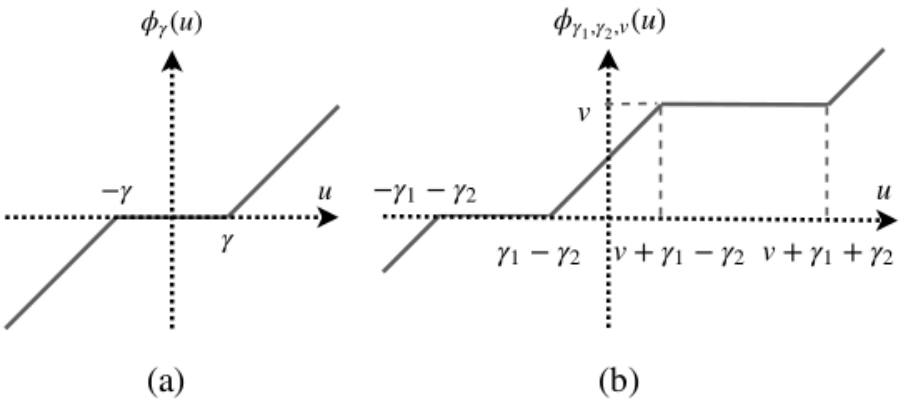
Σχήμα 3.1: Αλγόριθμος 1

$$\phi_{\gamma_1,\gamma_2,v}(u) = \begin{cases} u-\gamma_1-\gamma_2, & v+\gamma_1+\gamma_2 \le u < \infty, \\ v, & v+\gamma_1-\gamma_2 \le u < v+\gamma_1+\gamma_2, \\ u-\gamma_1+\gamma_2, & \gamma_1-\gamma_2 \le u < v+\gamma_1-\gamma_2, \\ 0, & -\gamma_1-\gamma_2 \le u < \gamma_1-\gamma_2, \\ u+\gamma_1+\gamma_2, & -\infty < u < -\gamma_1-\gamma_2 \end{cases}$$

για $v \ge 0$ και

$$\phi_{\gamma_1,\gamma_2,v}(u) = \begin{cases} u-\gamma_1-\gamma_2, & \gamma_1+\gamma_2 \le u < \infty, \\ 0, & -\gamma_1+\gamma_2 \le u < \gamma_1+\gamma_2, \\ u+\gamma_1-\gamma_2, & v-\gamma_1+\gamma_2 \le u < -\gamma_1+\gamma_2, \\ v, & v-\gamma_1-\gamma_2 \le u < v-\gamma_1+\gamma_2, \\ u-\gamma_1+\gamma_2, & -\infty < u < v-\gamma_1-\gamma_2 \end{cases} \tag{3.2}$$

για $v < 0$, όπου $\gamma_1 = \frac{\lambda_1}{\alpha}, \gamma_2 = \frac{\lambda_2}{\alpha}$ και v, u μια τιμή των $Gh_{t-1}^{()}, u$ αντίστοιχα. Στο Σχήμα 3.2 βλέπουμε τις γραφικές παραστάσεις της συνάρτησης ενεργοποίησης που χρησιμοποιεί η μέθοδος που ακολουθήσαμε και της αντίστοιχης συνάρτησης που συναντάμε στις μεθόδους LISTA και SISTA.



Σχήμα 3.2: Συναρτήσεις ϕ_γ (α) LISTA,SISTA και (β) $\ell_1 - \ell_1$ ελαχιστοποίησης

3.2 Περιγραφή της αρχιτεκτονικής του δικτύου

Σε αυτή την υποενότητα περιγράφονται οι τεχνικές λεπτομέρειες για την αρχιτεκτονική του δικτύου. Όπως αναφέρθηκε και προηγουμένως, το δίκτυο που κατασκευάσαμε έχει την μορφή ενός πολυεπίπεδου RNN, το οποίο σε κάθε επίπεδο υλοποιεί την λογική του αλγορίθμου του Σχήματος 2.1 που αναλύσαμε στην προηγούμενη υποενότητα.

Ειδικότερα, το δίκτυο αυτό σε κάθε κρυμμένο επίπεδο $k = 1, \ldots, K$ και για κάθε στιγμιότυπο του σήματος την χρονική στιγμή $t = 1, \ldots, T$ μας δίνει την αραιή αναπαράσταση του σήματος με τον εξής τρόπο:

$$h_t^{(k)} = \begin{cases} \phi_{\frac{\lambda_1}{\alpha},\frac{\lambda_2}{\alpha},Gh_{t-1}^{()}}(W^{(1)}h_{t-1}^{(1)} + Ux_t), & k = 1, \\ \phi_{\frac{\lambda_1}{\alpha},\frac{\lambda_2}{\alpha},Gh_{t-1}^{()}}(S^{(k)}h_{t-1}^{(1)} + Ux_t), & k > 1, \end{cases} \tag{3.3}$$

όπου U,W,S:

$$U = \frac{1}{\alpha}D^T A^T \tag{3.4}$$

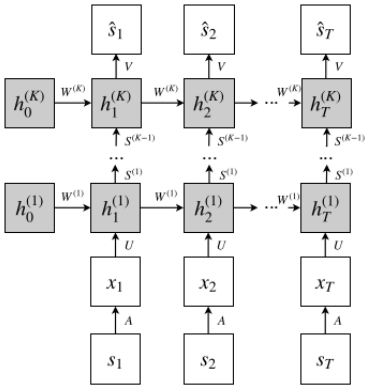
$$W = G - \frac{1}{\alpha}D^T A^T ADG \tag{3.5}$$

$$S = I - \frac{1}{\alpha}D^T A^T AD \tag{3.6}$$

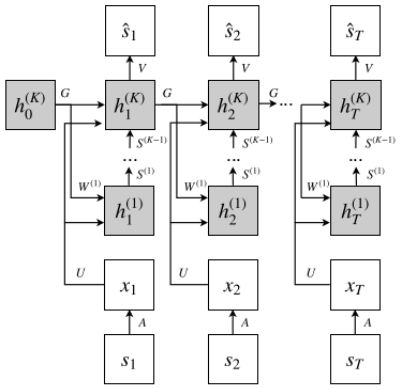
και I ο μοναδιαίος πίνακας. Το αναδημιουργημένο σήμα s_t όπως αναφέρθηκε και παραπάνω παράγεται από τον πολλαπλασιασμό της αραιής αναπαράστασης κάθε στιγμιότυπου που μας δίνει το τελευταίο κρυμμένο επίπεδο K με τον πίνακα D.

Για την εκπαίδευση του δικτύου χρησιμοποιούμε ως συνάρτηση σφάλματος το μέσο τετραγωνικό σφάλμα των σημάτων της εισόδου και της εξόδου:
$\mathcal{L} = \sum_{t=1}^{T} \|s_t - \hat{s}_t\|_2^2$ όπου $\hat{s}_t = Dh_t^{(K)}$.

Στο Σχήμα 3.3 βλέπουμε σχηματικά την αρχιτεκτονική του δικτύου που υλοποιήσαμε συγκριτικά με ένα απλό RNN πολλών κρυμμένων επιπέδων.



(a) A stacked RNN.



(b) The proposed model.

Σχήμα 3.3: α) ένα απλό RNN πολλών κρυμμένων επιπέδων. β) το δίκτυο που υλοποιήσαμε

3.3 Ανιχνευτής ανώμαλων στιγμιοτύπων

Σε αυτή την ενότητα θα μιλήσουμε για τον τρόπο που η μέθοδος μας αποφασίζει για το αν ένα καρέ ενός βίντεο περιέχει ασυνήθιστα γεγονότα ή όχι.

Για την ανίχνευση ανωμαλιών σε βίντεο μια συνήθης πρακτική σε μεθόδους που εφαρμόζουν μηχανική μάθηση είναι η καταγραφή του βίντεο, η εφαρμογή μιας μεθόδου εξαγωγής χαρακτηριστικών, και η λήψη της απόφασης εντοπισμού ανωμαλιών

με βάση τα εξαγόμενα χαρακτηριστικά. Η ιδέα είναι ότι τα ομαλά βίντεο διαφέρουν από τα μη ομαλά σε επίπεδο χαρακτηριστικών. Σε μεθόδους που χρησιμοποιούν αραιές αναπαραστάσεις έχει προταθεί η εξής πρακτική: Κάθε καρέ από το καταγεγραμμένο βίντεο αναλύεται σε αραιούς συντελεστές με χρήση ενός εκπαιδευμένου λεξικού. Η αραιή αναπαράσταση χρησιμοποιείται για ανακατασκευή του καρέ. Εάν το βίντεο είναι μη ομαλό, τότε η ανακατασκευή οδηγεί σε μεγάλο σφάλμα ανακατασκευής γιατί το λεξικό που χρησιμοποιήθηκε έχει εκπαιδευτεί σε ομαλά δεδομένα, συνεπώς οι αραιοί συντελεστές που εξάγονται με αυτή τη μέθοδο δεν μπορούν να ενσωματώσουν όλη την πληροφορία που απαιτείται για την επιτυχή ανακατασκευή.

Στην παρούσα εργασία θα ακολουθήσουμε αυτήν την πρακτική. Ωστόσο, για τον υπολογισμό του σφάλματος ανακατασκευής δεν επαρκούν τα συμπιεσμένα καρέ που χρησιμοποιεί το μοντέλο RNN που περιγράψαμε στην ενότητα 3.2, αλλά χρειαζόμαστε πρόσβαση σε ολόκληρη την πληροφορία. Για το λόγο αυτό αφαιρούμε από τη σχεδίασή μας τον πίνακα δειγματοληψίας A, δηλαδή, το βίντεο λαμβάνεται χωρίς συμπίεση. Μαθηματικά, αυτό ισοδυναμεί με χρήση του μοναδιαίου πίνακα ως πίνακα δειγματοληψίας, δηλαδή, $A = I$. Το μοντέλο που κατασκευάζουμε με αυτόν τον τρόπο, λαμβάνει ως είσοδο βίντεο, υπολογίζει την αραιή αναπαράστασή τους με το δίκτυο RNN, και δίνει το ανακατασκευασμένο βίντεο ως έξοδο. Συμπερασματικά, το δίκτυο που προτείνεται για την ανίχνευση ανωμαλιών είναι ένας αυτοκωδικοποιητής RNN.

Συγκεκριμένα, αφού τελειώσει η διαδικασία εκπαίδευσης του δικτύου, παίρνουμε ένα νέο υποσύνολο δεδομένων το οποίο περιέχει και φυσιολογικά δεδομένα όμοια με αυτά του συνόλου εκπαίδευσης, αλλά και βίντεο που περιέχουν ασυνήθιστα γεγονότα. Δίνουμε τα βίντεο αυτά ως είσοδο στο δίκτυο μας και παίρνουμε για κάθε καρέ της εισόδου το αναδημιουργημένο καρέ στην έξοδο του δικτύου. Έπειτα το πρόβλημα μας ουσιαστικά μοιάζει με ένα πρόβλημα κατηγοριοποίησης, όπου τα στιγμιότυπα χωρίζονται σε δύο κατηγορίες, 0 ή 1, δηλαδή φυσιολογικό ή ανωμαλία, ανάλογα με την τιμή του PSNR που υπολογίζουμε μεταξύ της αρχικής εικόνας και της εξόδου του δικτύου. Συγκρίνουμε δηλαδή την τιμή του PSNR με ένα κατώφλι, και αν το ξεπερνά θεωρούμε πως το καρέ δείχνει κάτι σύνηθες και κατηγοριοποιείται ως 0, αλλιώς ως 1.

ΚΕΦΑΛΑΙΟ 4

Παρουσίαση των πειραμάτων και των αποτελεσμάτων

Αυτό το κεφάλαιο χωρίζεται σε δύο υποενότητες. Στην πρώτη εξετάζουμε την επίδοση του δικτύου μας πάνω στην ανακατασκευή αραιού σήματος και στη συνέχεια στην δεύτερη υποενότητα βλέπουμε την επίδοση της μεθόδου μας πάνω στην ανίχνευση ανωμαλιών. Τα πειράματα εκτελέστηκαν όλα στον ίδιο υπολογιστή, τις προδιαγραφές του οποίου βλέπουμε στον Πίνακα 4.1.

Τεχνικά Χαρακτηριστικά Η/Υ	
επεξεργαστής	AMD Ryzen 5 1600 Six-Core Processor
μνήμη	15 GB
κάρτα γραφικών	NVIDIA GeForce GTX 1070

Πίνακας 4.1: Τεχνικά χαρακτηριστικά του μηχανήματος που εκτελέστηκαν τα πειράματα

Για τον προγραμματισμό της μεθόδου χρησιμοποιήσαμε την γλώσσα προγραμματισμού Python. Το δίκτυο υλοποιήθηκε με την χρήση της βιβλιοθήκης Pytorch, η οποία χρησιμοποιείται ευρέως στον προγραμματισμό μοντέλων deep learning. Για την αρχικοποίηση του λεξικού D χρησιμοποιήσαμε την βιβλιοθήκη sparselandtools, που παρέχει υπερπλήρεις μετασχηματισμούς σε μορφή πίνακα. Ο κώδικας είναι

διαθέσιμος στο github στο εξής αποθετήριο: github.com/ariss95/thesis

4.1 Πειράματα στην ανακατασκευή σήματος

4.1.1 Σύνολο δεδομένων

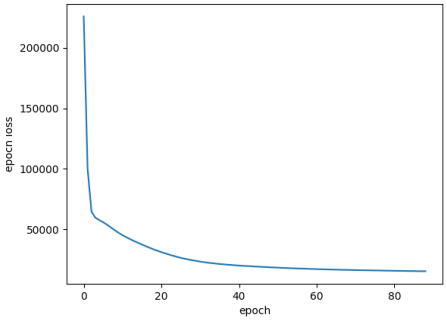
Για να αξιολογήσουμε το μοντέλο μας πάνω στην ανακατασκευή σήματος που έχει ληφθεί με συμπιεστική δειγματοληψία δοκιμάσαμε αρχικά το σύνολο δεδομένων moving MNIST. Πρόκειται για ένα σύνολο από 10000 βίντεο, όπου κάθε βίντεο έχει 20 καρέ στα οποία βλέπουμε δύο ψηφία από το σύνολο χειρόγραφων ψηφίων MNIST να κινούνται ομαλά στα όρια της εικόνας. Τα βίντεο αυτά δημιουργήθηκαν στο πλαίσιο της εργασίας [21] . Τα αρχικά καρέ είναι εικόνες διάστασης 64×64 όμως λόγω των πολλών μαθηματικών υπολογισμών που απαιτεί η μέθοδος χρησιμοποιήσαμε συμπιεσμένα καρέ διάστασης 16×16, όπως και οι συγγραφείς του [20]. Τα βίντεο διάστασης 16×16 λαμβάνονται από τα αρχικά με την χρήση του bilinear decimation. Τα αρχικό σύνολο δεδομένων είναι διαθέσιμο εδώ ενώ το επεξεργασμένο διάστασης 16×16 εδώ.

Το σύνολο δεδομένων χωρίζεται σε 3 υποσύνολα εκπαίδευσης, ελέγχου και επικύρωσης μεγέθους 8000 1000 και 1000 αντίστοιχα.

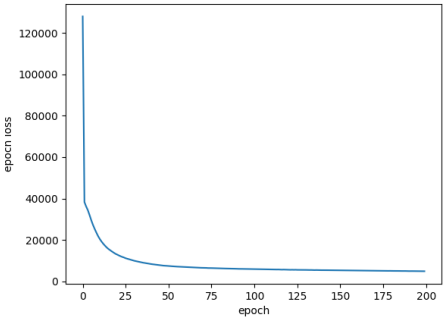
4.1.2 Λεπτομέρειες υλοποίησης

Οι παράμετροι του δικτύου που ενημερώνονται κατά την εκπαίδευση είναι οι πίνακες D, A, G, το αρχικό αραιό σήμα h_0, το α και οι παράμετροι κανονικοποίησης λ_1, λ_2. Για την ενημέρωσή τους χρησιμοποιούμε τον βελτιστοποιητή Adam με ρυθμό μάθησης 0,001. Η εκπαίδευση διαρκεί 200 εποχές σε υποσύνολα των 32 βίντεο, ενώ ως εποχή ορίζεται το πέρασμα όλων των παραδειγμάτων του συνόλου εκπαίδευσης από το δίκτυο. Οι αρχικές τιμές των παραμέτρων α, λ_1, λ_2 είναι οι ίδιες όπως και στο δίκτυο της εργασίας [20], ίσες δηλαδή με 1, 1 και 0.2 αντίστοιχα.

Δοκιμάσαμε και την μέθοδο του πρόωρου σταματήματος της εκπαίδευσης αλλά τα αποτελέσματα δεν ήταν καθόλου ικανοποιητικά. Στο Σχήμα 4.1α βλέπουμε την γραφική παράσταση του σφάλματος εκπαίδευσης ανά εποχή στην περίπτωση που σταματήσαμε την εκπαίδευση όταν η μείωση του σφάλματος ανά εποχή δεν ήταν μεγάλη, ενώ στο Σχήμα 4.1β βλέπουμε την αντίστοιχη γραφική παράσταση για 200



(α) Σφάλμα εκπαίδευσης με πρόωρο σταμάτημα



(β) Σφάλμα εκπαίδευσης μετά από 200 εποχές

Σχήμα 4.1: Απεικόνιση του σφάλματος εκπαίδευσης ανά εποχή.

εποχές. Το ότι τα αποτελέσματα δεν ήταν ικανοποιητικά φαίνεται και από την ελάχιστη τιμή του σφάλματος.

Για να μετρήσουμε την επίδοση του δικτύου υπολογίζουμε τη μέση τιμή του PSNR μεταξύ των καρέ της εισόδου και των αναδημιουργημένων καρέ του συνόλου ελέγχου. Το PSNR είναι μία εκτίμηση της ανθρώπινης αντίληψης πάνω στην ποιότητα της ανακατασκευασμένης εικόνας, και υπολογίζεται ως εξής:

$$PNSR = 20 * log_{10}(255/MSE)$$

για εικόνες 8 bits, όπου MSE το μέσο τετραγωνικό σφάλμα μεταξύ των καρέ. Γενικά, για εικόνες 8 bit βάθους, όταν το psnr είναι πάνω από **30dB** η ανακατασκευή θεωρείται ικανοποιητική.

4.1.3 Διερεύνηση Παραμέτρων

Σε αυτή την υποενότητα παρουσιάζονται τα πρώτα πειράματα που κάναμε με σκοπό να βρούμε τις καλύτερες παραμέτρους για το δίκτυο πάνω στο πρόβλημα της ανακατασκευής σήματος. Σε κάθε πίνακα που ακολουθεί η τιμή του PSNR είναι η μέση τιμή των παραδειγμάτων του συνόλου ελέγχου.

Ξεκινήσαμε ψάχνοντας την καλύτερη διάσταση του πίνακα D, δηλαδή το πλήθος των ατόμων (στηλών) που αντιστοιχεί στο πλήθος των κρυμμένων νευρώνων ανά επίπεδο.

Στις πρώτες εκτελέσεις του αλγορίθμου τα αποτελέσματα δεν ήταν ικανοποιητικά καθώς λόγω του ότι ο πίνακας A παίρνει τυχαίες ακέραιες τιμές ο θόρυβος

που προκαλούσε στα σήματα της εισόδου ήταν μεγάλος. Οπότε προσθέσαμε ως παράμετρο έναν ακέραιο με τον οποίο διαιρούμε τις αρχικές τιμές του πίνακα A ώστε να είναι εφικτή η ανακατασκευή των σημάτων.

Έπειτα, αφού κρατήσαμε ως διάσταση του D το 1024 που μας έδωσε τα καλύτερα αποτελέσματα δοκιμάσαμε διάφορες τιμές για τον διαιρέτη των τιμών του πίνακα A. Στη συνέχεια εκπαιδεύσαμε το δίκτυο με διαφορετικό πλήθος κρυμμένων επιπέδων. Τα αποτελέσματα των πειραμάτων παρουσιάζονται στους πίνακες που ακολουθούν.

Στον Πίνακα 4.2 βλέπουμε τις τιμές του psnr σε αναλογία με το πλήθος ατόμων του πίνακα D. Παρατηρούμε ότι όσο περισσότερους κρυμμένους νευρώνες έχουμε τόσο καλύτερα είναι τα αποτελέσματα, αλλά η διαφορά είναι σχετικά μικρή. Ο λόγος που δοκιμάσαμε μόνο τετραγωνικούς αριθμούς για την διάσταση του λεξικού D προκύπτει από την βιβλιοθήκη Sparselandtools που χρησιμοποιήσαμε για να πάρουμε τους διακριτούς μετασχηματισμούς συνημιτόνου, καθώς ο αλγόριθμος τους περιμένει ως είσοδο τις τετραγωνικές ρίζες των διαστάσεων του πίνακα που θέλουμε. Για παράδειγμα για πίνακα 256×625 δίνουμε το 16 και το 25 αντίστοιχα ως είσοδο.

ρυθμός συμπίεσης: 33%, κρυμμένα επίπεδα: 3	
πλήθος ατόμων πίνακα D	μέση τιμή PSNR
400	35.79 dB
625	36.54 dB
900	36.57 dB
1024	**36.63 dB**

Πίνακας 4.2: Επίδραση του πλήθους ατόμων (στηλών) του λεξικού D στην επίδοση του δικτύου.

Στον Πίνακα 4.3 βλέπουμε τα αποτελέσματα για διαφορετικές τιμές στον διαιρέτη των τιμών του πίνακα A, με τις διαφορές στο αποτέλεσμα να μην είναι πολύ μεγάλες.

ρυθμός συμπίεσης: 33%, κρυμμένα επίπεδα: 3, πλήθος ατόμων πίνακα D: 1024	
διαιρέτης πίνακα A	μέση τιμή PSNR
50	36.02 dB
100	**36.88 dB**
150	36.63 dB
200	36.58 dB
250	36.54 dB
1000	36.63 dB

Πίνακας 4.3: Επίδραση του διαιρέτη των τιμών του πίνακα A στην επίδοση του δικτύου.

Μια ακόμα παράμετρος του δικτύου που διερευνήθηκε αφορά τον αριθμό των κρυμμένων επιπέδων. Τα αποτελέσματα αυτής της διερεύνησης παρουσιάζονται στον Πίνακα 4.4.

ρυθμός συμπίεσης 33%, πλήθος ατόμων πίνακα D: 1024	
κρυμμένα επίπεδα	μέση τιμή PSNR
2	34.30 dB
3	36.88 dB
4	**39.20 dB**

Πίνακας 4.4: Επίδραση του αριθμού κρυμμένων επιπέδων στην επίδοση του δικτύου.

Με βάση τα παραπάνω κρατήσαμε ως διαιρέτη για τον A το 100, και δοκιμάσαμε την επίδοση του δικτύου σε διαφορετικές διαστάσεις του πίνακα A, δηλαδή διαφορετικούς ρυθμούς συμπίεσης.

διαιρέτης πίνακα A = 100, κρυμμένα επίπεδα : 4	
ρυθμός συμπίεσης	μέση τιμή PSNR
50%	35.34 dB
33%	39.20 dB
25%	34.46 dB
20%	30.86 dB

Πίνακας 4.5: Επίδραση του ρυθμού συμπίεσης στην επίδοση του δικτύου.

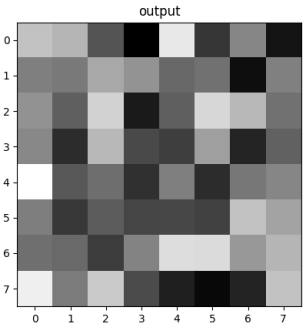
Από τις τιμές του PSNR που βλέπουμε στον Πίνακα 4.5 παρατηρούμε ότι για ρυθμό συμπίεσης 50% τα αποτελέσματα δεν είναι τα αναμενόμενα,καθώς περιμέναμε η ποιότητα ανακατασκευής να είναι ανάλογη του ρυθμού συμπίεσης. Αξιοποιώντας προηγούμενη παρατήρηση για την επίδραση του εύρους τιμών του πίνακα A στην ποιότητα ανακατασκευής, δοκιμάσαμε διαφορετικές τιμές για τον διαιρέτη του A και καταλήξαμε στην τιμή 200, η οποία οδηγεί σε **PSNR = 44.37 dB** για ρυθμό συμπίεσης 50%.

Από τον Πίνακα 4.4 προκύπτει ότι όσα περισσότερα κρυμμένα επίπεδα έχουμε τόσο καλύτερα αποτελέσματα έχουμε. Δεν δοκιμάσαμε περισσότερα από 4 κρυμμένα επίπεδα καθώς θα αυξανόταν πολύ το κόστος των υπολογισμών.

4.1.4 Οπτικά αποτελέσματα ανακατασκευής στιγμιοτύπων των βίντεο

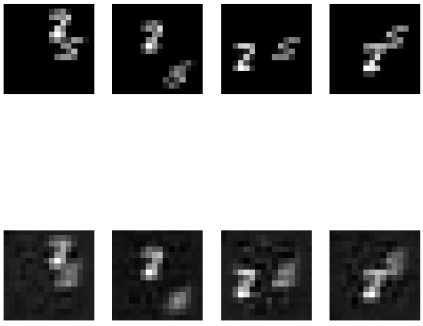
Στην ενότητα αυτή παρουσιάζουμε με τη μορφή εικόνων κάποια καρέ που πήραμε από το δίκτυο είτε κατά την διάρκεια της εκπαίδευσης είτε μετά από αυτήν και κατά την φάση του ελέγχου.

Αρχικά βλέπουμε στο Σχήμα 4.2 ένα καρέ διάστασης 8×8, το οποίο προκύπτει μετά τον πολλαπλασιασμό ενός καρέ της εισόδου με τον πίνακα A, διάστασης 256×64, δηλαδή με ρυθμό συμπίεσης 20%.



Σχήμα 4.2: Συμπιεστική δειγματοληψία: Παράδειγμα καρέ μετά τον πολλαπλασιασμό με τον πίνακα A

Στα καρέ του Σχήματος 4.3 βλέπουμε την έξοδο του δικτύου για ένα από τα πρώτα δοκιμαστικά πειράματα που πραγματοποιήσαμε στο οποίο πήραμε χαμηλό μέσο psnr, κάτι που γίνεται εύκολα αντιληπτό και με το ανθρώπινο μάτι καθώς υπάρχουν αισθητές διαφορές στην ποιότητα των αρχικών και των αναδημιουργημένων εικόνων. Στο συγκεκριμένο πείραμα εκπαιδεύσαμε το δίκτυο για 200 εποχές με ρυθμό συμπίεσης 50% χωρίς να διαιρέσουμε με κάποιον αριθμό τις τιμές του Πίνακα A.



Σχήμα 4.3: Παράδειγμα ανακατασκευής στιγμιοτύπων που έχουν ληφθεί με ρυθμό συμπίεσης 50%. Στην πρώτη σειρά παρουσιάζονται τα αρχικά στιγμιότυπα και στη δεύτερη τα αποτελέσματα ανακατασκευής. Η χαμηλή ποιότητα ανακατασκευής οφείλεται στην ανεπιτυχή αρχικοποίηση του πίνακα δειγματοληψίας A.

Στο Σχήμα 4.4 βλέπουμε κατά σειρά τέσσερα στιγμιότυπα από δύο βίντεο στην

πρώτη γραμμή και από κάτω τους το αντίστοιχο αναδημιουργημένο καρέ που πήραμε ως έξοδο από το δίκτυο μας. Τα αποτελέσματα του Σχήματος 4.4 προέρχονται από το τελικό πείραμα που μας έδωσε την καλύτερη τιμή PSNR στο σύνολο ελέγχου, κάτι που φαίνεται και οπτικά καθώς δύσκολα εντοπίζει κανείς διαφορές μεταξύ της πρώτης και της δεύτερης σειράς.



Σχήμα 4.4: Παράδειγμα ανακατασκευής στιγμιοτύπων που έχουν ληφθεί με ρυθμό συμπίεσης 50%, διαιρέτη για τον πίνακα A το 200, 4 κρυμμένα επίπεδα και λεξικό D 1024 στηλών.

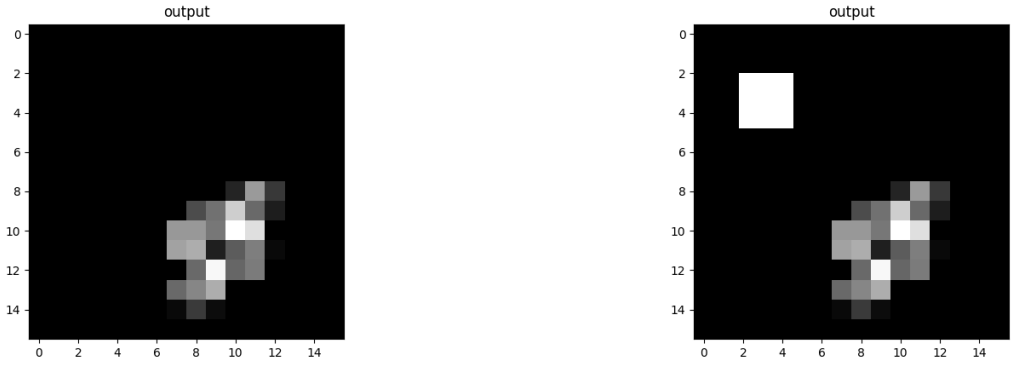
4.2 Πειράματα στην ανίχνευση ανωμαλιών

Εφόσον μέσα από τα πειράματα της προηγούμενης ενότητας βρήκαμε τις κατάλληλες παραμέτρους για το δίκτυο μας πάνω στην ανακατασκευή σήματος, προχωρήσαμε στην αξιολόγηση της μεθόδου πάνω στην ανίχνευση καρέ που περιέχουν μη συνηθισμένα γεγονότα.

4.2.1 Σύνολο δεδομένων

Για την αξιολόγηση της μεθόδου που υλοποιήσαμε πάνω στην ανίχνευση ανωμαλιών πήραμε ένα υποσύνολο του moving MNIST και το παραποιήσαμε ώστε να δημιουργήσουμε μη φυσιολογικά καρέ. Συγκεκριμένα, σε κάποιες ακολουθίες στιγμιοτύπων του συνόλου επαλήθευσης, πήραμε τυχαία ένα από τα 20 καρέ και προσθέσαμε θό-

ρυβο. Η ιδέα προέκυψε από την εργασία [22], όπου οι συγγραφείς χρησιμοποίησαν το συγκεκριμένο σύνολο δεδομένων πάνω στην ανίχνευση ανωμαλιών. Εν αντιθέσει με την εργασία [22] όπου για την κατασκευή μη φυσιολογικών καρέ ζωγράφισαν μαύρα 3×3 μπλοκ πάνω σε άσπρα pixel, χρωματίσαμε κάποια μπλοκ μαύρων pixel από το φόντο με άσπρο. Ένα παράδειγμα παραποιημένου καρέ δίνεται στο Σχήμα 4.5.



Σχήμα 4.5: Παράδειγμα παραποιημένου καρέ που χρησιμοποιήθηκε για ανίχνευση ανωμαλιών. Στα αριστερά βλέπουμε το αρχικό στιγμιότυπο και δεξιά το τροποποιημένο.

4.2.2 Αξιολόγηση μεθόδου

Σε αυτή την υποενότητα πούμε κάποια λόγια για τις μετρικές που χρησιμοποιήσαμε ώστε να αξιολογήσουμε την απόδοση του μοντέλου μας στην ανίχνευση ανωμαλιών πάνω στα επεξεργασμένα παραδείγματα του moving Mnist.

Γενικά, σε προβλήματα κατηγοριοποίησης βρίσκουμε τους όρους αληθώς και ψευδώς θετικό ή αρνητικό. Στην περίπτωση της ανίχνευσης ανωμαλιών, όταν για ένα μη φυσιολογικό παράδειγμα μια μέθοδος το κατηγοριοποιεί ως ανωμαλία το παράδειγμα αυτό προσμετράται στο πλήθος των ορθώς θετικών (true positive - tp), ενώ αν το κρίνει ως φυσιολογικό στο πλήθος των ψευδώς αρνητικών (false negative - fn). Αντίστοιχα για ένα φυσιολογικό παράδειγμα αν το κατηγοριοποιήσουμε ως ανωμαλία θα προστεθεί στα ψευδώς θετικά (false positive - fp) ενώ αν κρίνουμε σωστά θα προστεθεί στα ορθώς αρνητικά (true negative - tn).

Για να μετρήσουμε την απόδοση της μεθόδου που υλοποιήσαμε πάνω στην ανίχνευση ανωμαλιών υπολογίσαμε τις τιμές ακρίβειας(precision) και ανάκλησης(recall), καθώς και τον λόγο των πραγματικά ανώμαλων στιγμιοτύπων ως προς τους λάθους

συναγερμούς, δηλαδή τα ψευδώς τα αρνητικά.Με βάση τα πλήθη των παραπάνω(tp, fp , tn, fn) υπολογίζονται και οι τιμές της ακρίβειας και της ανάκλησης:

$$precision = \frac{tp}{tp + fp}$$

$$recall = \frac{tp}{tp + fn}$$

Ουσιαστικά η ακρίβεια είναι ένας τρόπος μέτρησης ποιότητας, ενώ η ανάκληση ποσότητας.Δηλαδή, σε ένα πείραμα η υψηλή ακρίβεια σημαίνει πως η μέθοδος εντοπίζει περισσότερα μη φυσιολογικά στιγμιότυπα από φυσιολογικά, ενώ η υψηλή ανάκληση μας λέει πως ο αλγόριθμος βρίσκει τα περισσότερα από τα ανώμαλα στιγμιότυπα του συνόλου δεδομένων.

4.3 Μοντέλο χωρίς συμπίεση

Σε αυτή την υποενότητα βλέπουμε τα αποτελέσματα του δικτύου πάνω σε παραδείγματα τα οποία δεν έχουν υποστεί συμπιεστική δειγματοληψία, όπως αναφέρθηκε και στην υποενότητα 3.3. Όπως βλέπουμε και στον Πίνακα 4.6, η μέθοδος δεν δουλεύει στην πράξη καθώς δεν εντοπίζει τα μη φυσιολογικά καρέ επιτυχώς. Μάλιστα σε περιπτώσεις με χαμηλή τιμή κατωφλίωσης δεν έχουμε καν αποτελέσματα για την μετρική της ακρίβειας λόγω διαίρεσης με το 0.

anomaly detection			
κατώφλι(dB)	true positive/false positive	ακρίβεια	ανάκληση
20	0/0	-	0
30	4/1	0.8	0.062
40	14/51	0.215	0.046

Πίνακας 4.6: Αποτελέσματα της προτεινόμενης μεθόδου ανίχνευσης ανωμαλιών βίντεο για διάφορες τιμές κατωφλίου

Το παραπάνω προκύπτει λόγω της μη χρήσης του πίνακα A στο δίκτυο, καθώς όπως βλέπουμε και στο Σχήμα 4.6 η έλλειψη συμπίεσης από το μοντέλο κάνει την ανακατασκευή πιο εύκολη ακόμα και για παραδείγματα που διαφέρουν με αυτά του

συνόλου εκπαίδευσης. Η συμπιεσμένη πληροφορία εισόδου κάνει την ανακατασκευή πιο δύσκολη, και τελικά το μοντέλο που χρησιμοποιεί συμπίεση αποτυγχάνει να ανακτήσει τα μη ομαλά βίντεο, οπότε στην επόμενη ενότητα παρουσιάζουμε τα αποτελέσματα της μεθόδου μετά από συμπιεστική δειγματοληψία.



Σχήμα 4.6: Παράδειγμα επιτυχούς ανακατασκευής μη ομαλού στιγμιότυπου βίντεο. Στη δεξιά στήλη απεικονίζεται το στιγμιότυπο εισόδου, ενώ αριστερά παρουσιάζεται το ανακατασκευασμένο στιγμιότυπο.

4.4 Μοντέλο με συμπίεση

Αφού η ιδέα του αυτοκωδικοποιητή RNN απέτυχε, χρησιμοποιήσαμε το ίδιο σύνολο δεδομένων με τα παραποιημένα καρέ πάνω στο μοντέλο που περιέχει και τον πίνακα δειγματοληψίας A.

Στους Πίνακες 4.7 και 4.8 που ακολουθούν βλέπουμε συγκεντρωτικά την επίδοση του δικτύου με βάση τις μετρικές που αναφέραμε στην υποενότητα 4.2.2. Αρχικά στον Πίνακα 4.7 βλέπουμε τις τιμές των μετρικών για 3 τιμές κατωφλίωσης που χρησιμοποιήσαμε. Παρατηρούμε πως με κατώφλι 20dB έχουμε υψηλή ακρίβεια, καθώς δεν υπάρχουν ψευδώς θετικά παραδείγματα, ενώ η ανάκληση δεν είναι τόσο μεγάλη επειδή υπάρχουν αρκετά ψευδώς αρνητικά. Το αντίθετο συμβαίνει για κατώφλι 30dB, καθώς έχουμε πολλά ψευδώς θετικά και λίγα ψευδώς αρνητικά, ενώ για 25dB που έχουμε μόλις τρία ψευδώς θετικά βλέπουμε μια ακρίβεια πολύ κοντά στο 100%, αλλά παράλληλα έχουμε και ικανοποιητική ανάκληση.

anomaly detection			
κατώφλι(dB)	true positive/false positive	ακρίβεια	ανάκληση
20	850/0	1.0	0.856
25	902/3	0.996	0.909
30	939/318	0.747	0.946

Πίνακας 4.7: Αποτελέσματα της προτεινόμενης μεθόδου ανίχνευσης ανωμαλιών βίντεο για διάφορες τιμές κατωφλίου

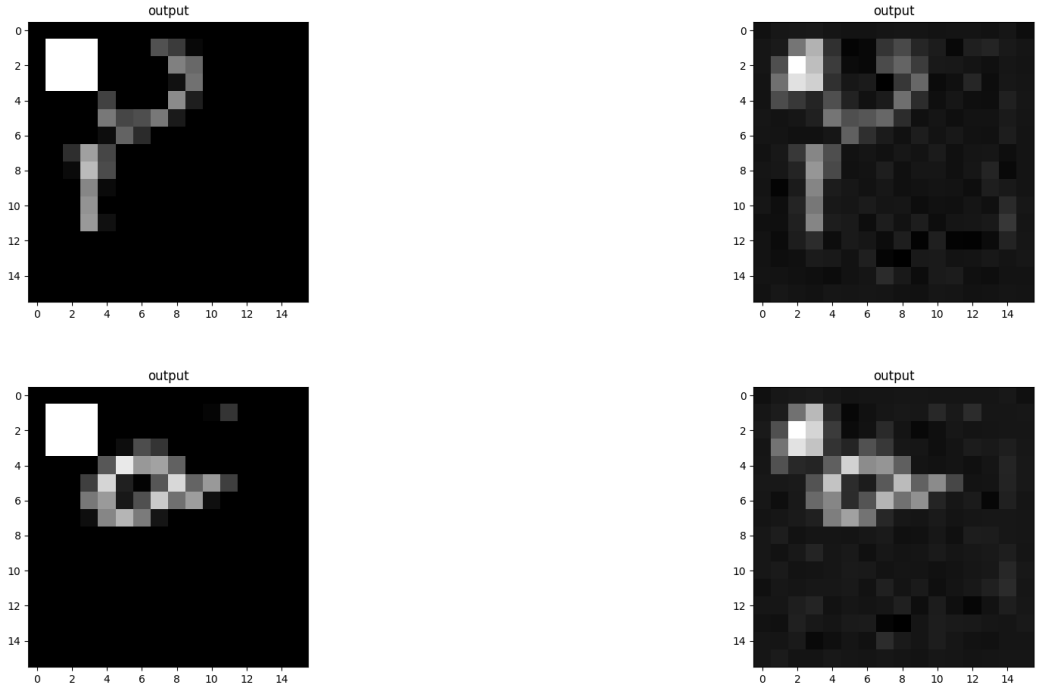
Στον Πίνακα 4.8 βλέπουμε τον λεγόμενο πίνακα σύγχυσης (confusion matrix) για κατώφλι ίσο με 25dB. Ο πίνακας αυτός μας λέει ουσιαστικά τι σημαίνουν τα tp, fp , tn, fn.

prediction / label	anomalous	normal
anomalous	902	90
normal	3	18845

Πίνακας 4.8: Πίνακας σύγχυσης για κατώφλι 25dB

4.4.1 Οπτικά αποτελέσματα ανώμαλων στιγμιοτύπων

Σε αυτή την υποενότητα παρουσιάζουμε όπως και στην υποενότητα 4.1.4 τα αποτελέσματα ανακατασκευής στιγμιοτύπων βίντεο σε περιπτώσεις ομαλότητας και περιπτώσεις ανωμαλιών. Στο Σχήμα 4.7 βλέπουμε το αποτέλεσμα της ανακατασκευής σε δύο καρέ τα οποία έχουμε παραποιήσει και είναι ξεκάθαρο ότι το δίκτυο δεν αποδίδει καλά με αυτά ως είσοδο οπότε ορθώς κρίνει πως τα στιγμιότυπα αυτά περιέχουν κάτι το μη φυσιολογικό.



Σχήμα 4.7: Παραδείγματα ανακατασκευής μη ομαλών στιγμιοτύπων βίντεο. Στη δεξιά στήλη απεικονίζεται το στιγμιότυπο εισόδου, ενώ αριστερά παρουσιάζεται το ανακατασκευασμένο στιγμιότυπο.

Από την άλλη στο Σχήμα 4.8 βλέπουμε ένα παράδειγμα που εσφαλμένα κρίθηκε ως ανώμαλο στιγμιότυπο, είναι δηλαδή ψευδώς θετικό. Αυτό ίσως συμβαίνει επειδή τα χειρόγραφα ψηφία στο συγκεκριμένο καρέ δεν μοιάζουν αρκετά με άλλα ίδια ψηφία που έχει δει το δίκτυο κατά την εκπαίδευση. Ακόμα και με γυμνό μάτι ο αριστερά αριθμός δεν φαίνεται ξεκάθαρα αν είναι το οκτώ ή κάποιος άλλος.



Σχήμα 4.8: Παράδειγμα ψευδώς θετικού καρέ

ΚΕΦΑΛΑΙΟ 5

Συμπεράσματα

Με βάση τα αποτελέσματα του μοντέλου μας στο σύνολο δεδομένων moving MNIST βλέπουμε ότι η ιδέα της παρούσας εργασίας δουλεύει και μπορεί να έχει πρακτική εφαρμογή πάνω στην ανίχνευση ανωμαλιών σε βίντεο. Δοκιμάσαμε να κάνουμε πειράματα και στο σύνολο uscd Ped1, ένα σύνολο δεδομένων με βίντεο από κάμερα που καταγράφει πεζούς να κινούνται στον προαύλιο χώρο ενός πανεπιστημίου και χρησιμοποιείται ευρέως στην ανίχνευση ανωμαλιών. Το πρόβλημα όμως είναι ότι σε αντίθεση με το moving MNIST τα καρέ των βίντεο του ucsd ped1 είναι αρκετά μεγαλύτερα σε πλάτος και ύψος, οπότε κατά συνέπεια το αποθηκευτικό κόστος αυξήθηκε λόγω και των μεγαλύτερων διαστάσεων του πίνακα A και του λεξικού D, οπότε δεν καταφέραμε να ολοκληρώσουμε τα πειράματα. Στη συνέχεια δοκιμάσαμε να συμπιέσουμε τα βίντεο σε καρέ 100×100 και να μειώσουμε το πόσα καρέ απαρτίζουν ένα βίντεο αλλά σε αυτή την περίπτωση η ποιότητα των αρχικών καρέ ήταν αρκετά χαμηλή με αποτέλεσμα τα μη φυσιολογικά γεγονότα να μη διαφέρουν από τα φυσιολογικά.

Κατά συνέπεια, ένα ανοιχτό πεδίο για μελλοντική ενασχόληση είναι η δοκιμή του δικτύου μας σε κάποιο άλλο σύνολο δεδομένων και μετά από αυτό η σύγκριση των αποτελεσμάτων της μεθόδου με αυτά των υπολοίπων που αναφέρθηκαν στο κεφάλαιο 1. Για να συμβεί αυτό θα πρέπει είτε να μελετηθεί παραπάνω η μέθοδος ανακατασκευής ώστε να μπορεί να λειτουργήσει με λιγότερες παραμέτρους, για παράδειγμα με λεξικό D μικρότερης διάστασης είτε να εκτελεστούν πειράματα σε υπολογιστή με μεγαλύτερες δυνατότητες που δεν θα επηρεάζεται από το μεγάλο κόστος της εκπαίδευσης του δικτύου.

ΒΙΒΛΙΟΓΡΑΦΙΑ

[1] B. Ramachandra, M. Jones, and R. R. Vatsavai, "A survey of single-scene video anomaly detection," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2020.

[2] B. Zhao, L. Fei-Fei, and E. P. Xing, "Online detection of unusual events in videos via dynamic sparse coding," in *CVPR 2011*. IEEE, 2011, pp. 3313–3320.

[3] C. Lu, J. Shi, and J. Jia, "Abnormal event detection at 150 fps in matlab," in *Proceedings of the IEEE international conference on computer vision*, 2013, pp. 2720–2727.

[4] Y. Cong, J. Yuan, and J. Liu, "Abnormal event detection in crowded scenes using sparse representation," *Pattern Recognition*, vol. 46, no. 7, pp. 1851–1864, 2013.

[5] C. Lu, J. Shi, W. Wang, and J. Jia, "Fast abnormal event detection," *International Journal of Computer Vision*, vol. 127, no. 8, pp. 993–1011, 2019.

[6] M. Hasan, J. Choi, J. Neumann, A. K. Roy-Chowdhury, and L. S. Davis, "Learning temporal regularity in video sequences," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.

[7] J. R. Medel and A. Savakis, "Anomaly detection in video using predictive convolutional long short-term memory networks," *arXiv preprint arXiv:1612.00390*, 2016.

[8] M. Ravanbakhsh, M. Nabi, E. Sangineto, L. Marcenaro, C. Regazzoni, and N. Sebe, "Abnormal event detection in videos using generative adversarial nets," in *2017 IEEE International Conference on Image Processing (ICIP)*. IEEE, 2017, pp. 1577–1581.

[9] M. Elad, "Sparse and redundant representations: from theory to applications in signal and image processing," 2010.

[10] D. L. Donoho and M. Elad, "Optimally sparse representation in general (nonorthogonal) dictionaries via l1 minimization," *Proceedings of the National Academy of Sciences*, vol. 100, no. 5, pp. 2197–2202, 2003.

[11] R. Tibshirani, "Regression shrinkage and selection via the lasso," *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 58, no. 1, pp. 267–288, 1996.

[12] R. G. Baraniuk, "Compressive sensing [lecture notes]," *IEEE Signal Processing Magazine*, vol. 24, no. 4, pp. 118–121, 2007.

[13] A. Ribes and F. Schmitt, "Linear inverse problems in imaging," *IEEE Signal Processing Magazine*, vol. 25, no. 4, pp. 84–99, 2008.

[14] J. A. Tropp and S. J. Wright, "Computational methods for sparse solution of linear inverse problems," *Proceedings of the IEEE*, vol. 98, no. 6, pp. 948–958, 2010.

[15] A. Balatsoukas-Stimming and C. Studer, "Deep unfolding for communications systems: A survey and some new directions," in *2019 IEEE International Workshop on Signal Processing Systems (SiPS)*. IEEE, 2019, pp. 266–271.

[16] I. Daubechies, M. Defrise, and C. De Mol, "An iterative thresholding algorithm for linear inverse problems with a sparsity constraint," *Communications on Pure and Applied Mathematics: A Journal Issued by the Courant Institute of Mathematical Sciences*, vol. 57, no. 11, pp. 1413–1457, 2004.

[17] K. Gregor and Y. LeCun, "Learning fast approximations of sparse coding," in *Proceedings of the 27th international conference on international conference on machine learning*, 2010, pp. 399–406.

[18] S. Wisdom, T. Powers, J. Pitton, and L. Atlas, "Building recurrent networks by unfolding iterative thresholding for sequential sparse recovery," in *2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, 2017, pp. 4346–4350.

[19] E. Tsiligianni and N. Deligiannis, "Deep coupled-representation learning for sparse linear inverse problems with side information," *IEEE Signal Processing Letters*, vol. 26, no. 12, pp. 1768–1772, 2019.

[20] H. D. Le, H. Van Luong, and N. Deligiannis, "Designing recurrent neural networks by unfolding an l1-l1 minimization algorithm," *arXiv preprint arXiv:1902.06522*, 2019.

[21] N. Srivastava, E. Mansimov, and R. Salakhudinov, "Unsupervised learning of video representations using lstms," in *International conference on machine learning*. PMLR, 2015, pp. 843–852.

[22] I. Ben-Ari and R. Shwartz-Ziv, "Attentioned convolutional lstm inpaintingnetwork for anomaly detection in videos," *arXiv preprint arXiv:1811.10228*, 2018.